شناخت داده و توصیف آماری

تحلیل فاز اول | زیرمجموعهٔ NACC: UDS + MRI

پرسش پروژه

در این زیرمجموعهٔ تحویلی، نمرهٔ خام MoCA و ضخامت قشر انتورینال چگونه توزیع شده‌اند و این توزیع‌ها در گروه‌های وضعیت شناختی ثبت‌شده در UDS چه تفاوت‌های توصیفی دارند؟

نتیجهٔ توصیفی	شاخص
۱,۲۳۷	افراد یکتای متصل‌شده
۱,۲۳۷ ردیف در هر فایل	فایل UDS و فایل MRI
۱,۲۲۸	افراد دارای هر دو وجه
۶۸.۱۹ سال	میانگین سن در UDS
۲۴.۳۹	میانگین نمرهٔ MOCATOTS معتبر
۳.۰۱ میلی‌متر	میانگین ضخامت دوطرفهٔ انتورینال

دامنه و احتیاط در تفسیر

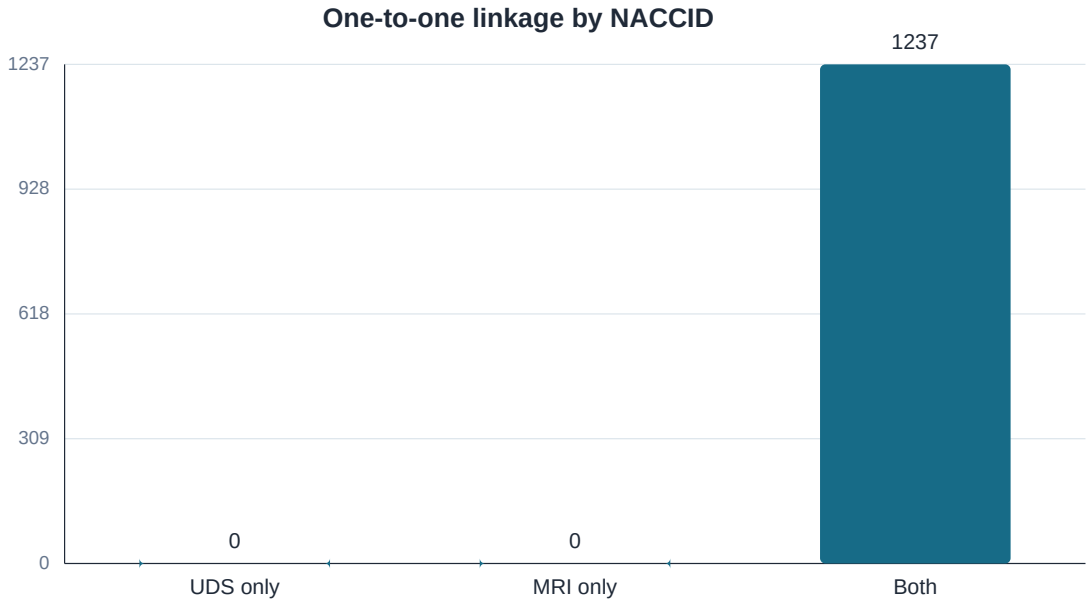
این گزارش توصیفی است و آزمون فرض یا ادعای علّی ارائه نمی‌کند. داده‌ها از یک زیرمجموعهٔ بالینی/پژوهشی NACC می‌آیند و نمونهٔ احتمالی جمعیت عمومی نیستند؛ بنابراین درصدهای این فایل را نباید شیوع جمعیتی دانست. نام فایل UDS نشان می‌دهد داده پردازش‌شده و imputed است، ولی روش جایگذاری و نقاب دادهٔ اولیه همراه فایل نیست.

تاریخ تولید: ۳۰ اکتبر ۲۰۲۶

۱. منبع داده، طرح مطالعه و واحد تحلیل

منبع پروژه، زیرمجموعهٔ آماده‌شدهٔ NACC (National Alzheimer's Coordinating Center) است. دو فایل تحویلی شامل UDS با متغیرهای جمعیت‌شناختی، پزشکی، عملکردی و شناختی و MRI با اندازه‌گیری‌های ساختاری قشری هستند. این مجموعه یک مطالعهٔ مشاهده‌ای در نمونهٔ بالینی/پژوهشی است؛ افراد به‌صورت تصادفی از جمعیت عمومی انتخاب نشده‌اند.

در هر دو فایل ۱,۲۳۷ ردیف و ۱,۲۳۷ شناسهٔ یکتا وجود دارد. شناسهٔ NACCID به‌صورت یک‌به‌یک استفاده شد. همهٔ شناسه‌ها در فایل مقابل پیدا شدند؛ عدم تطابق صفر بود. کد NACCUDSD در دو فایل برای هر فرد همسان بود. این شواهد، اتصال شناسه‌ای را پشتیبانی می‌کند، اما تاریخ مراجعه و تاریخ MRI در فایل‌ها نیست؛ بنابراین هم‌زمانی بالینی دو اندازه‌گیری را نمی‌توان اثبات کرد.



شکل ۱. شمار افرادِ یکتا در اتصال UDS و MRI. فقط یک ردیف برای هر شناسه در فایل موجود است؛ شناسه یا تاریخ مراجعه در فایل‌ها نیست.

تعداد ردیف‌ها را باید تعداد رکوردهای تحویلی دانست. فایل‌ها برای محاسبهٔ تعداد واقعی مراجعه‌ها یا انتخاب نخستین/نزدیک‌ترین مراجعه اطلاعات کافی ندارند. در فاز بعد، قاعدهٔ انتخاب یک مشاهده برای هر فرد باید حفظ شود و فاصلهٔ زمانی MRI–UDS، در صورت دسترسی به تاریخ‌ها، گزارش شود.

۲. نقشهٔ متغیرها و قواعد کیفیت داده

نقش و تعریف در این تحلیل	نوع/مقیاس	وجه و متغیر
سن در رکورد UDS	کمی پیوسته؛ سال	NACCAGE
کد ۹۹ طبق کدنامه به‌صورت نامعلوم کنار گذاشته شد	کمی گسسته؛ سال تحصیل	EDUC
خام؛ متغیر شناختی اصلی MoCA	نمرهٔ کمی؛ ۰ تا ۳۰	MOCATOTS
گروه‌بندی وضعیت شناختی	طبقه‌ای؛ ۴ سطح	NACCUDSD
شدت بالینی و طبقه‌بندی CDR	نمره/طبقهٔ مرتب	CDRGLOB و CDRSUM
ضخامت متوسط چپ و راست؛ میانگین دوطرفه تعریف‌شده در پروژه	کمی پیوسته؛ میلی‌متر	ENTORHINAL_AVGTH
حجم مادهٔ خاکستری؛ ممیزی وجه MRI	کمی پیوسته؛ میلی‌متر مکعب	ENTORHINAL_GVOL

قواعد ممیزی و تصمیم تحلیلی

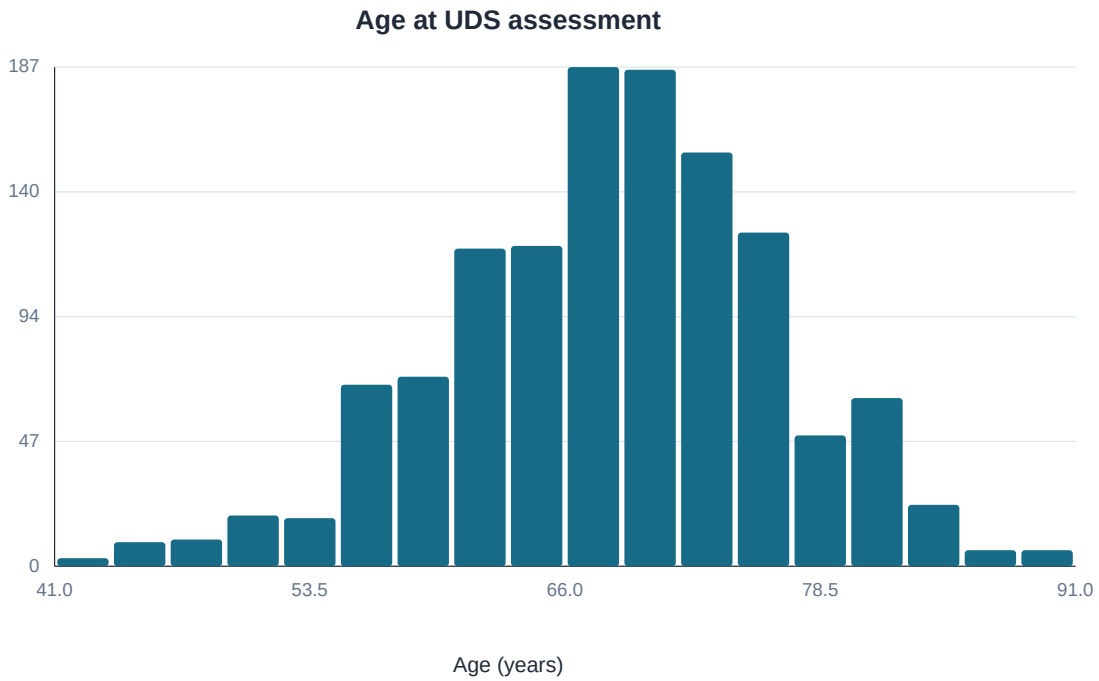
در سلول‌های دادهٔ اصلی مقدار خالی ثبت‌شده وجود نداشت. این به معنی نبود گمشدگی در دادهٔ اولیه نیست، چون فایل UDS جایگذاری‌شده است و روش/نقاب اولیه موجود نیست. مطابق کدنامهٔ NACC، EDUC=99 در دو نفر نامعلوم است و از محاسبهٔ سال‌های تحصیل کنار گذاشته شد. برای MOCATOTS فقط بازهٔ معتبر ۰ تا ۳۰ نگه داشته شد: ۹ مقدار خارج از این بازه کنار گذاشته شد (کد ۸۸ چهار بار، ۳۰٫۸ یک بار، ۳۴٫۲ یک بار، ۳۸٫۸ یک بار و ۳۹٫۴ دو بار). مقادیر محدود یا گرد نشدند.

از ۱٬۲۲۸ مقدار معتبر MOCATOTS، تعداد ۲۴۴ مقدار اعشاری است. این ویژگی با فایل جایگذاری‌شده سازگار است، ولی منشأ هر مقدار از فایل حاضر قابل ردیابی نیست؛ بنابراین همهٔ خلاصه‌ها «مقادیر معتبر موجود در فایل پردازش‌شده» هستند، نه دادهٔ خام مشاهده‌شده. به‌عنوان حساسیت توصیفی، محدودکردن محاسبه به مقادیر صحیح n=984 و میانگین ۲۴٫۰۳ می‌دهد؛ این زیرنمونه را نباید observed-case واقعی نامید.

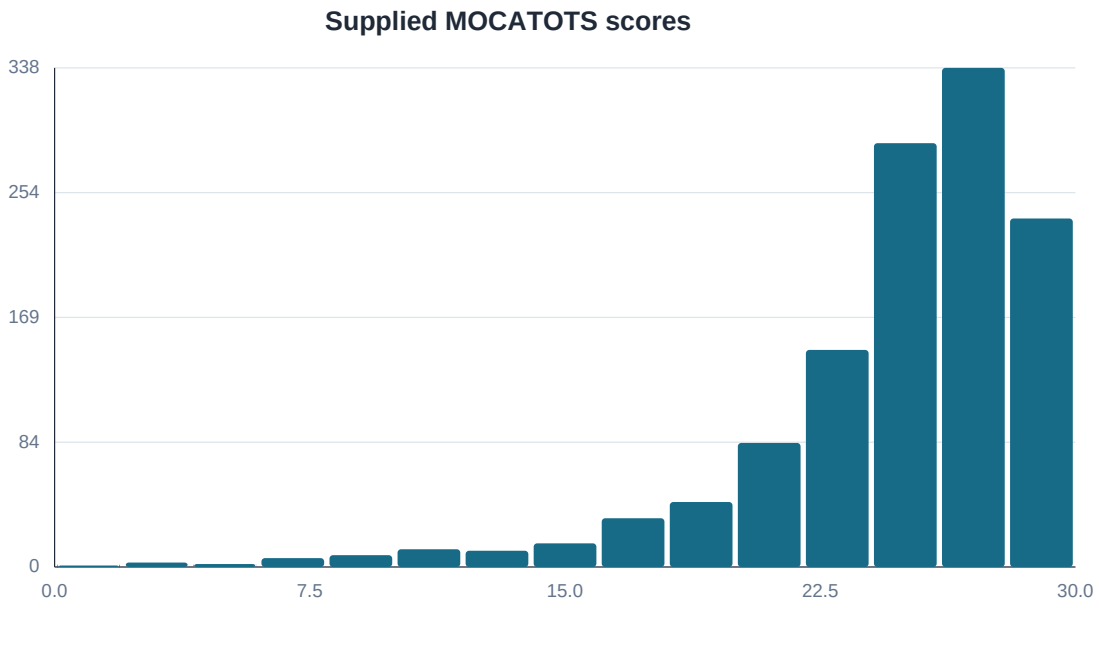
MRI برابر بود. دو سلول حجم CDR مجاز است نیم‌نمره داشته باشد. مجموع آن در تمام ۱٬۲۳۷ ردیف با جمع شش مؤلفهٔ CDRSUM غیرمثبت دیده شد: یک حجم انتورینال چپ و یک حجم posterior cingulate چپ برابر صفر؛ برای حجم انتورینال در این گزارش از مقدار صفر استفاده نشد. برای ضخامت قشری حد بالای دلخواه وضع نشد؛ مستندات رسمی برای این ستون‌ها دامنهٔ عددی تعیین نکرده‌اند.

۳. آمار توصیفی نمونه و متغیرهای اصلی

متغیر	n	میانگین	انحراف معیار	میانه	چارک ۱–۳	کمینه–بیشینه	واحد
سن	۱,۲۳۷	۶۸.۱۹	۸.۰۴	۶۸	۶۳ تا ۷۴	۴۱ تا ۹۱	سال
تحصیلات	۱,۲۳۵	۱۶.۲۶	۲.۷۲	۱۶	۱۴ تا ۱۸	۰ تا ۲۵	سال
خام MoCA	۱,۲۲۸	۲۴.۳۹	۴.۴۲	۲۵.۴۰	۲۳ تا ۲۷	۰ تا ۳۰	نمره
CDR Sum of Boxes	۱,۲۳۷	۰.۸۲	۱.۷۲	۰	۰ تا ۱	۰ تا ۱۵	نمره
ضخامت انتورینال دوطرفه	۱,۲۳۷	۳.۰۱	۰.۳۶	۳.۰۶	۲.۸۰ تا ۳.۲۵	۱.۲۱ تا ۳.۹۲	میلی‌متر



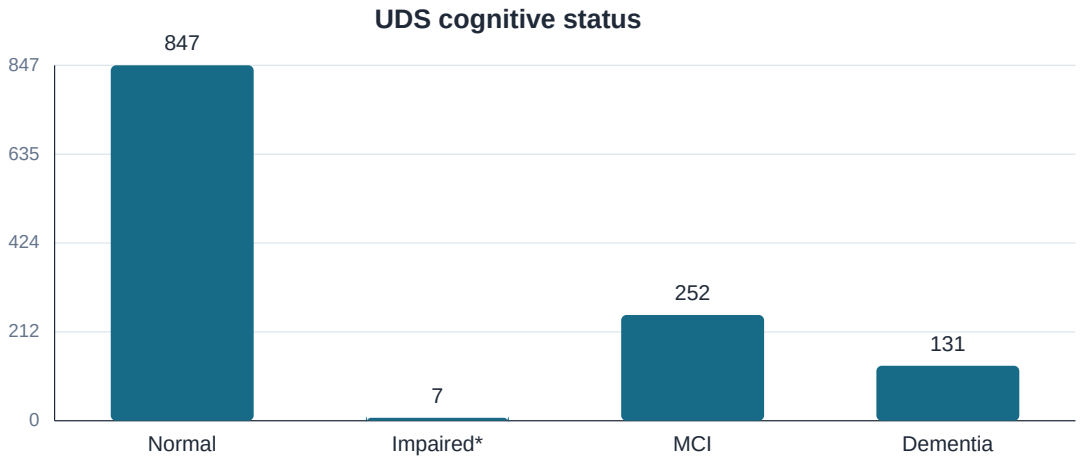
شکل ۲. توزیع سن ثبت‌شده در UDS؛ دامنهٔ مشاهده‌شده ۴۱ تا ۹۱ سال است.



شکل ۳. توزیع مقادیر MOCATOTS در بازهٔ معتبر. وجود مقادیر اعشاری بازتاب فایل پردازش‌شده است.

۴. فراوانی متغیرهای طبقه‌ای و مقایسهٔ توصیفی

متغیر	کد	طبقه	تعداد	درصد
SEX	1	مرد	۴۹۷	۴۰.۲٪
SEX	2	زن	۷۴۰	۵۹.۸٪
NACCUDSD	1	وضعیت شناختی طبیعی	۸۴۷	۶۸.۵٪
NACCUDSD	2	اختلال، بدون MCI	۷	۰.۶٪
NACCUDSD	3	اختلال شناختی خفیف (MCI)	۲۵۲	۲۰.۴٪
NACCUDSD	4	دمانس	۱۳۱	۱۰.۶٪
CDRGLOB	0.0	بدون اختلال	۸۰۰	۶۴.۷٪
CDRGLOB	0.5	مشکوک	۳۶۸	۲۹.۷٪
CDRGLOB	1.0	خفیف	۶۰	۴.۹٪
CDRGLOB	2.0	متوسط	۹	۰.۷٪



شکل ۴. فراوانی وضعیت شناختی ثبت‌شده در UDS. گروه «اختلال، بدون MCI» فقط ۷ نفر دارد و خلاصهٔ آن بسیار کم‌حجم است.

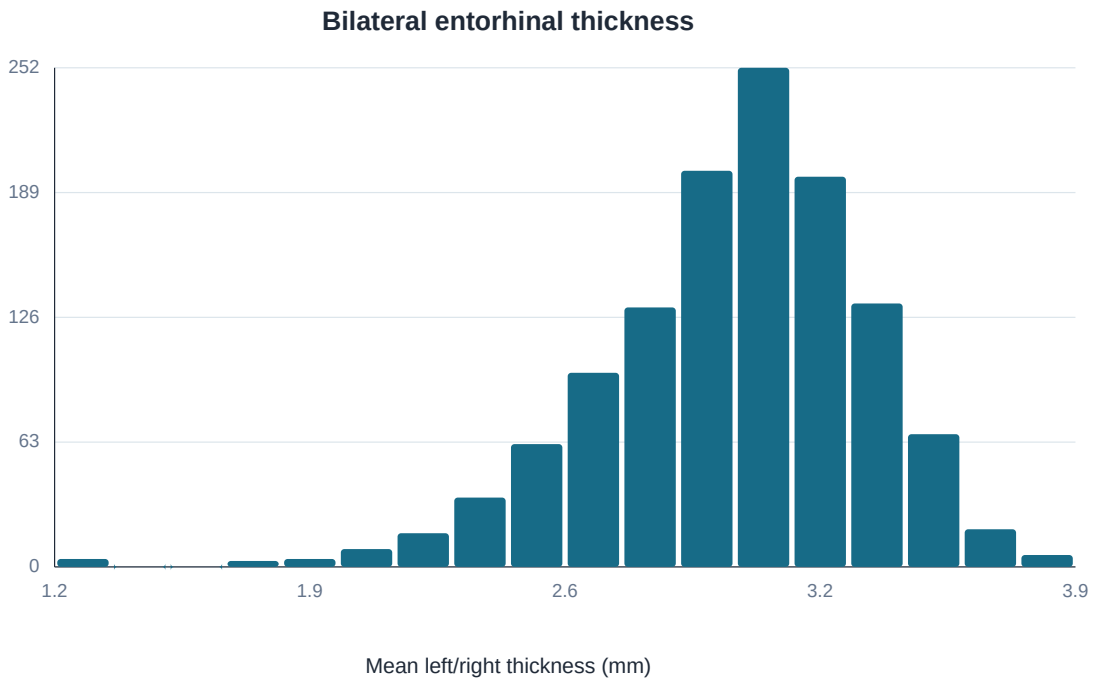
در مقایسهٔ صرفاً توصیفی، میانهٔ MOCATOTS از ۲۶٫۲ در گروه وضعیت شناختی طبیعی (n معتبر=۸۴۲) به ۲۳٫۰ در MCI (n=251) و ۱۷٫۰ در دمانس (n=128) می‌رسد. میانهٔ ضخامت دوطرفهٔ انتورینال به‌ترتیب ۳٫۱۰، ۲٫۹۷ و ۲٫۶۹ میلی‌متر است. این الگو توصیفی است؛ در این فاز، برای اختلاف گروهی آزمون یا استنباط جمعیتی انجام نمی‌شود.

وضعیت	گروه n	MoCA nمیانه ؛ (IQR)	ضخامت n؛ میانه (IQR), mm
Normal cognition	۸۴۷	۸۴۲؛ ۲۶.۲۰ (۲۵–۲۸)	۸۴۷؛ ۳.۱۰ (۲.۹۳–۳.۳۰)
Impaired, not MCI	۷	۷؛ ۲۶.۸۰ (۲۵.۸۰–۲۷.۷۰)	۷؛ ۳.۱۹ (۳.۱۳–۳.۳۷)
MCI	۲۵۲	۲۵۱؛ ۲۳ (۲۰–۲۵)	۲۵۲؛ ۲.۹۷ (۲.۶۹–۳.۱۹)
Dementia	۱۳۱	۱۲۸؛ ۱۷ (۱۳–۲۱)	۱۳۱؛ ۲.۶۹ (۲.۴۶–۲.۹۵)

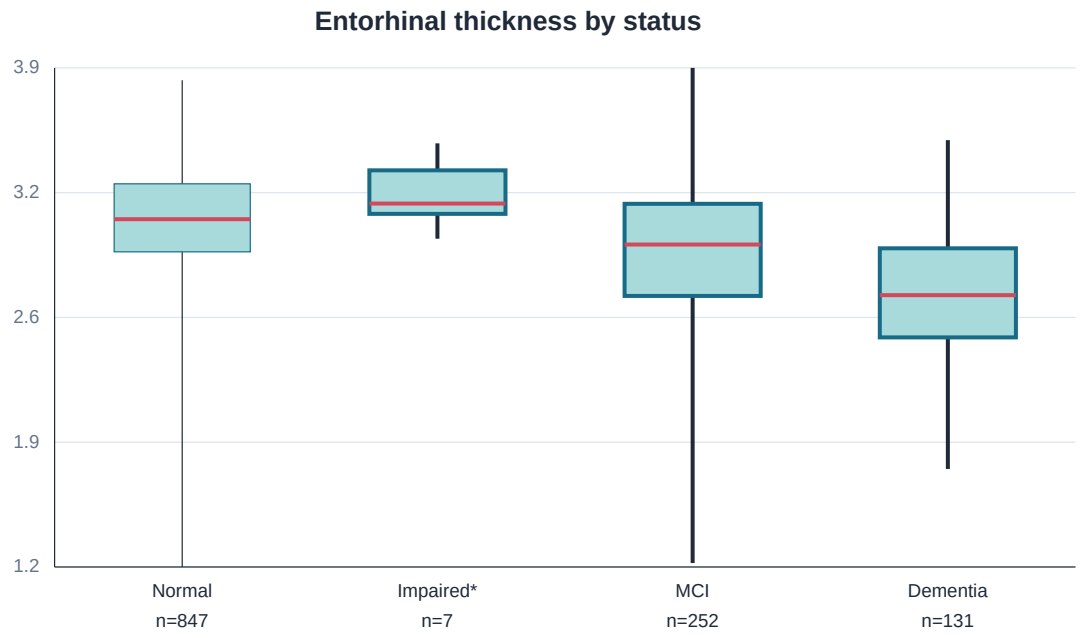
۵. خلاصهٔ وجه MRI و پیوند با UDS

نام ستون‌های محلی با نام‌های دفترچهٔ رسمی MRI مطابقت دارد: AVGTH ضخامت متوسط بر حسب میلی‌متر و GVOL حجم مادهٔ خاکستری بر حسب میلی‌متر مکعب است. در این پروژه، ضخامت دوطرفه به‌صورت میانگین سادهٔ ستون چپ و راست تعریف شد، مشروط بر اینکه هر دو مقدار مثبت باشند. این خلاصه‌سازی یک تعریف تحلیلی است؛ اسکن‌های دو طرف جداگانه نیز در CSV آمار توصیفی موجود هستند.

متغیر MRI	n	میانگین	SD	میانه	چارک ۱–۳	دامنه	واحد
ضخامت سمت چپ	۱,۲۳۷	۲.۹۷	۰.۳۸	۳.۰۲	۲.۷۶ تا ۳.۲۳	۰.۸۸ تا ۳.۹۸	میلی‌متر
ضخامت سمت راست	۱,۲۳۷	۳.۰۶	۰.۴۰	۳.۱۰	۲.۸۵ تا ۳.۳۲	۰.۷۳ تا ۳.۹۷	میلی‌متر
میانگین دوطرفه	۱,۲۳۷	۳.۰۱	۰.۳۶	۳.۰۶	۲.۸۰ تا ۳.۲۵	۱.۲۱ تا ۳.۹۲	میلی‌متر

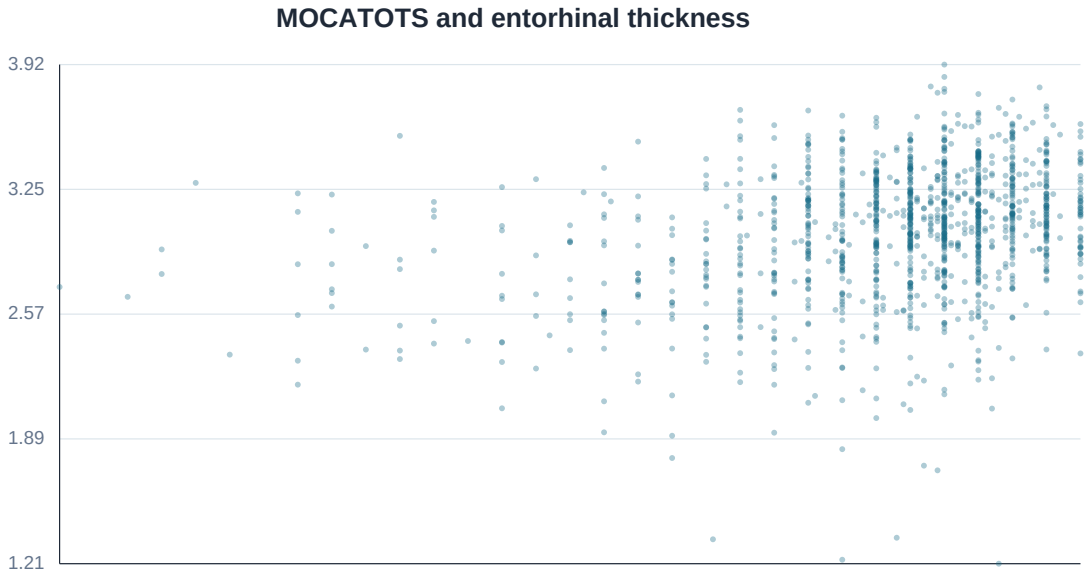


شکل ۵. توزیع ضخامت دوطرفهٔ قشر انتورینال؛ n=۱,۲۳۷. مقادیر دورافتاده حذف نشده‌اند.

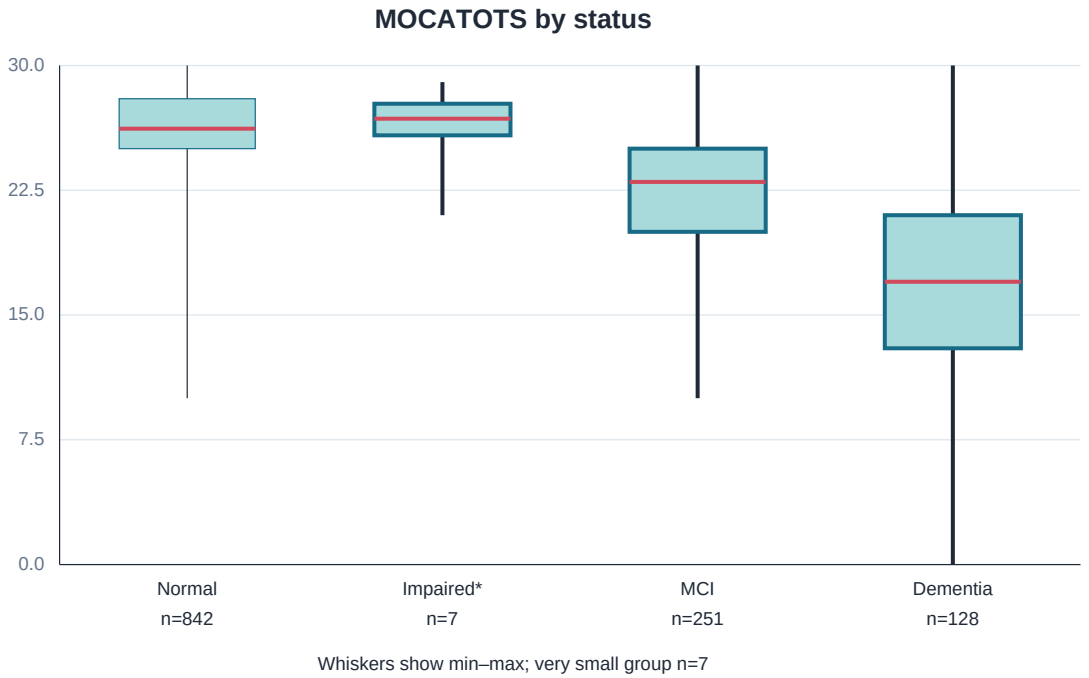


شکل ۶. جعبه‌نمودار توصیفی ضخامت قشر انتورینال برحسب کد وضعیت شناختی؛ خطوط جعبه میانه و چارک‌ها را نشان می‌دهند و سبیل‌ها کمینه–بیشینه را.

۶. رابطهٔ توصیفی دو وجه



شکل ۷. پراکنش نمرهٔ MOCATOTS معتبر و ضخامت دوطرفهٔ انتورینال. هر نقطه یک فرد یکتاست. نمودار برای دیدن الگو و پراکندگی است و رابطهٔ علّی یا اثر مستقل را نشان نمی‌دهد.



شکل ۸. توزیع نمرهٔ شناختی در گروه‌ها. تفاوت در پراکندگی، به‌ویژه در گروه دمانس، با صرف یک میانگین خلاصه نمی‌شود. گروه کد ۲ به علت n=۷ باید جداگانه و با احتیاط خوانده شود.

سؤال آماری برای ادامهٔ پروژه تثبیت شد: توصیف و مقایسهٔ توزیع MOCATOTS و ضخامت دوطرفهٔ انتورینال در میان گروه‌های تشخیصی در افراد حاضر در زیرمجموعهٔ چندوجهی. در فازهای بعدی، پیش از هر استنباط باید زمان مراجعه/تصویربرداری، تعریف NACCUDSD امتیازهای جایگذاری‌شده، انتخاب مشاهدهٔ مستقل و فروض مدل بررسی شوند.

۷. گمشدگی، انتخاب نمونه و محدودیت تعمیم

متغیر اصلی	قابل استفاده n	نامعلوم/خارج دامنه	درصد
NACCAGE	۱,۲۳۷	۰	۰.۰٪
EDUC	۱,۲۳۵	۲	۰.۲٪
MOCATOTS	۱,۲۲۸	۹	۰.۷٪
NACCUDSD	۱,۲۳۷	۰	۰.۰٪
CDRGLOB	۱,۲۳۷	۰	۰.۰٪
CDRSUM	۱,۲۳۷	۰	۰.۰٪
LH_ENTORHINAL_AVGTH	۱,۲۳۷	۰	۰.۰٪
RH_ENTORHINAL_AVGTH	۱,۲۳۷	۰	۰.۰٪
LH_ENTORHINAL_GVOL	۱,۲۳۶	۱	۰.۱٪
RH_ENTORHINAL_GVOL	۱,۲۳۷	۰	۰.۰٪

در این اتصال، هر ۱,۲۳۷ نفر در هر دو فایل حضور دارند؛ پس گروه «فاقد MRI» در دادهٔ تحویلی وجود ندارد. مقایسهٔ افراد دارای MRI و فاقد آن از این زیرمجموعه قابل برآورد نیست. این نبود گروه مقایسه باید به‌عنوان محدودیت انتخاب/دسترس‌پذیری تفسیر شود؛ با صفر پرکردن گروه ساخته نشد.

فایل‌ها شناسهٔ مراجعه، تاریخ ارزیابی UDS، تاریخ اسکن MRI، شناسهٔ مرکز، متغیرهای کنترل کیفیت MRI، نسخهٔ FreeSurfer و تاریخ دورهٔ گردآوری را ندارند. بنابراین تعداد واقعی مراجعه‌ها، فاصلهٔ زمانی UDS تا MRI، کیفیت عبور اسکن از پروتکل، بازنمایی افراد واجد شرایطی که در فایل نیستند و دورهٔ جمع‌آوری قابل احراز نیست. کدنامهٔ NACC نیز بر این نکته تأکید می‌کند که وضعیت شناختی تشخیص علت‌شناختی آلزایمر نیست NACCUDSD.

جمعیت مورد تفسیر به همین نمونهٔ چندوجهی موجود در فایل‌ها محدود است. NACC دادهٔ بالینی/پژوهشی گردآوری می‌کند و نمونهٔ حاضر نمونه‌گیری تصادفی ملی نیست. همبستگی یا اختلاف توصیفی احتمالی را نباید علت تلقی کرد. نتایج گروه کوچک کد ۲ و نمره‌های دارای اثر جایگذاری، به‌ویژه عدم قطعیت دارند.

۸. بازتولید، فایل‌ها و منابع

کد اصلی در src/phase1_analysis.py تمام اتصال‌ها، قواعد معتبرسازی، جدول‌های JSON، CSV نتایج و نمودارهای SVG را از سه فایل داده می‌سازد. فایل‌های خام بازنویسی نمی‌شوند. پس از اجرای تحلیل، src/build_phase1_report.py گزارش PDF فارسی را می‌سازد.

محتوا	خروجی
نتایج عددی، ممیزی، فراوانی‌ها و توضیح طراحی	reports/phase1/phase1_results.json
خلاصهٔ توزیع متغیرهای کمی	reports/phase1/descriptive_statistics.csv
فراوانی و درصد طبقات	reports/phase1/categorical_frequencies.csv
خلاصهٔ توصیفی در گروه‌های NACCUDSD	reports/phase1/group_summaries.csv
شمار و درصد نامعلوم یا خارج دامنه	reports/phase1/missingness.csv
نمودارهای قابل بزرگ‌نمایی، قابل ویرایش و مستقل	figures/phase1/*.svg
راهنمای اجرا و تفسیر نتایج	notebooks/phase1_descriptive_analysis.ipynb

مراحل اجرا

از ریشهٔ پروژه: python3 src/phase1_analysis.py؛ سپس با پایتون محیط GapGPT که ReportLab و ابزار شکل‌دهی فارسی دارد، فایل src/build_phase1_report.py اجرا شود. فایل‌های PDF در مسیرهای reports/phase1.pdf و reports/phase1/report_phase1.pdf قرار می‌گیرند. کتابخانه‌های گزارش requirements.txt در PDF ثبت شده‌اند.

منابع رسمی

NACC UDS Researcher’s Data Dictionary, Version 3.0 (صفحه‌های متغیرهای MOCATOTS، EDUC با اصلاحیه‌های بعدی) CDR و NACCUDSD.

NACC SCAN & CLARiTI MRI Researcher’s Data Dictionary، نام و واحد متغیرهای MRI.

NACC Researcher’s Guide، بخش پیوند تصویربرداری با مراجعه‌های UDS و محدودیت تفسیر نمونه.

پیوندهای منابع

UDS dictionary: https://files.alz.washington.edu/documentation/uds3-rdd.pdf
MRI dictionary: https://files.alz.washington.edu/documentation/SCAN-MRI-Imaging-RDD.pdf
NACC Researcher’s Guide: https://www.naccdata.org/the-nacc-researchers-guide

سند چارچوب پروژه: amarpr.pdf، بخش فاز اول و الزامات اختصاصی مسیر NACC. تاریخ دریافت داده در پوشهٔ محلی ثبت نشده است.